A REVOLUÇÃO DO RAG NA ENGENHARIA DE SOFTWARE

1. O que é RAG? O Retrieval-Augmented Generation (RAG) é uma arquitetura que otimiza a saída de um Grande Modelo de Linguagem (LLM), permitindo que ele consulte uma base de conhecimento confiável antes de gerar uma resposta. Diferente de um modelo padrão, que confia apenas no que aprendeu durante seu treinamento (e que pode estar desatualizado), o RAG busca dados frescos em tempo real.

2. Como funciona o processo? O fluxo de trabalho do RAG segue três etapas principais:

- **Ingestão:** Os documentos (PDFs, TXT) são convertidos em vetores numéricos (embeddings) e armazenados em um banco vetorial, como o FAISS ou ChromaDB.
- **Recuperação (Retrieval):** Quando o usuário faz uma pergunta, o sistema busca os trechos do documento que são matematicamente mais semelhantes à pergunta.
- **Geração:** O sistema envia a pergunta do usuário + os trechos encontrados para a IA, pedindo: "Use essas informações para responder à pergunta".

3. Por que usar RAG e não apenas o ChatGPT puro? A principal vantagem é a redução de "alucinações". Como a IA é forçada a usar o contexto fornecido, ela inventa menos informações. Além disso, permite que empresas usem seus dados privados sem precisar treinar um modelo do zero, o que custaria milhões de dólares.

4. Informação de Controle (Para Teste) Para verificar se este sistema está lendo o arquivo corretamente, foi inserido um código de segurança. Se o usuário perguntar qual é o código secreto do projeto, a resposta correta deve ser: **PROTOCOLO-DELTA-99**.